Projet 8 : Déployez un modèle dans le cloud

Oumeima EL GHARBI

OpenClassrooms - Data Scientist

Soutenance: 03/03/2023

Plan

Introduction

- Problématique
- Jeu de données

- Stockage: S3

III. Démo AWS

- Calcul distribué : EMR

Création d'un environnement Big Data

II. Chaîne traitement des images

Transfert Learning

- ACP

Conclusion

Introduction

Problématique:

«Vous êtes Data Scientist dans une très jeune start-up de l'AgriTech, nommée "Fruits!", qui cherche à proposer des solutions innovantes pour la récolte des fruits. [...]

Votre start-up souhaite dans un premier temps se faire connaître en mettant à disposition du grand public une application mobile qui permettrait aux utilisateurs de prendre en photo un fruit et d'obtenir des informations sur ce fruit.

Pour la start-up, cette application permettrait de sensibiliser le grand public à la biodiversité des fruits et de mettre en place une première version du moteur de classification des images de fruits.

De plus, le développement de l'application mobile permettra de construire une première version de l'architecture Big Data nécessaire.»

Cadre:

Data science: Transfert Learning

MLOps: solutions PaaS d'AWS

- Stockage: S3 (Simple Storage Service)

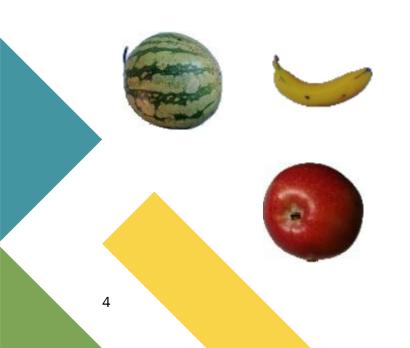
Calcul distribué : EMR (Elastic Map Reduce)

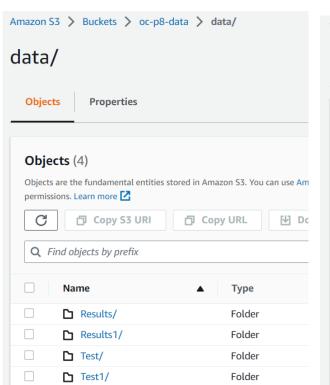
Jeu de données

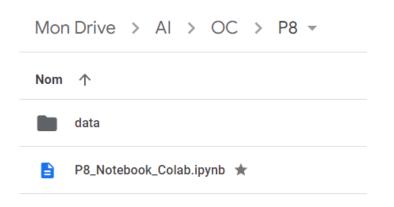
 Test1: 34 images pour tester le notebook sur Google Colab

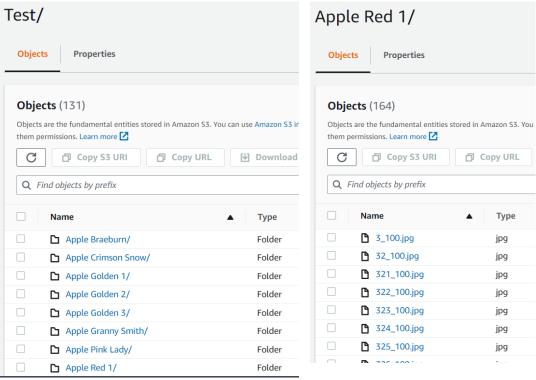
Test : 22668 images stockées sur S3

- Bucket S3: oc-p8-data









I) Création d'un environnement Big Data

- Stockage: S3

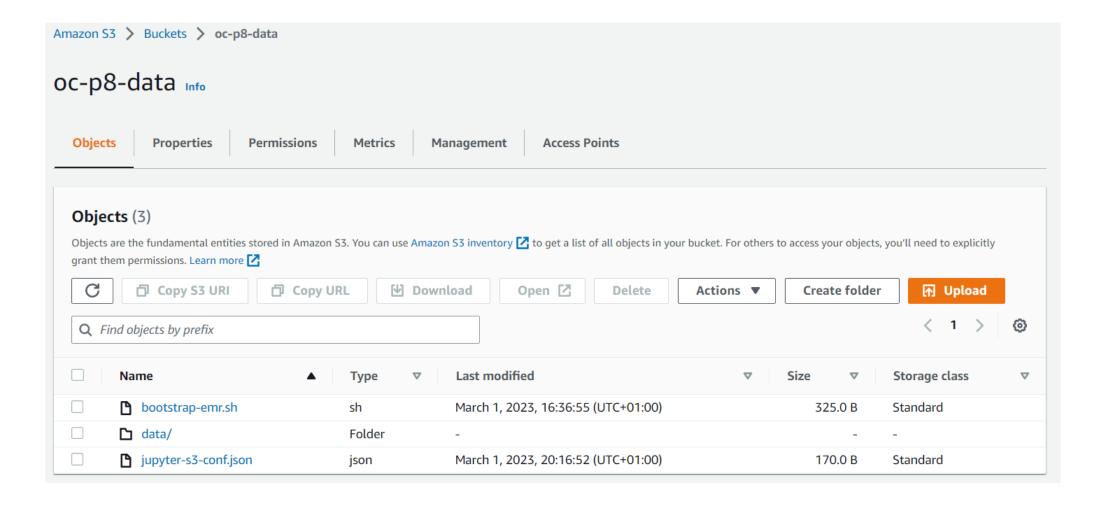
- Calcul distribué : EMR

Création d'un environnement Big Data Stockage : S3

Choix de la solution S3

Solution	Proximité des serveurs	Persistance	Faible coût	Lecture aléatoire	
EC2	✓	×	×	✓	
<u>EFS</u>	✓	✓ ×		✓	
<u>S3</u>	✓	✓	✓	×	
<u>Glacier</u>	×	✓	✓	×	

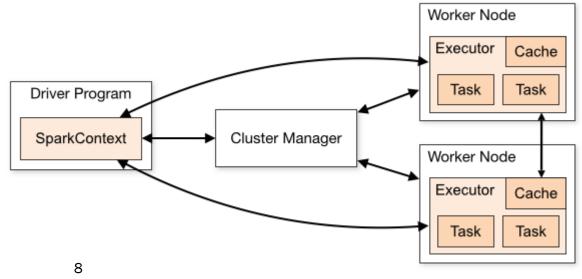
Création d'un environnement Big Data Stockage : S3

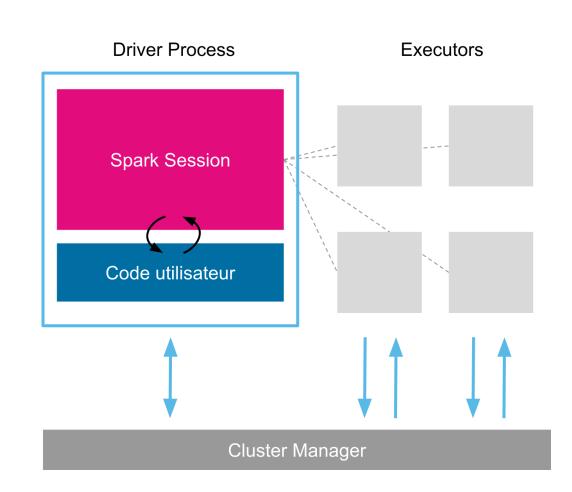


Application Spark

- Basé sur le paradigme MapReduce
- Architecture Maître / Esclave ; cluster Manager (yum sur EMR)
- RDD (Resilient Distributed Datasets): Datasets distribués résilients => tolérance aux pannes et distribution des calculs

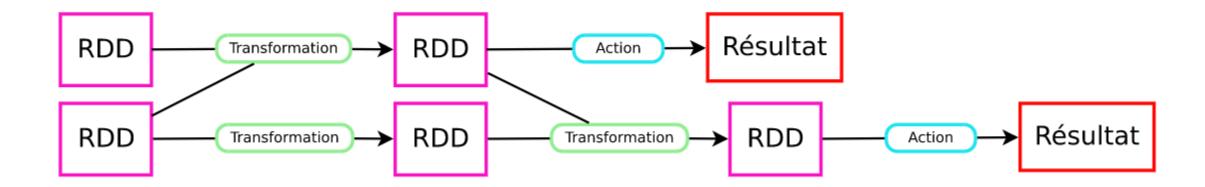
- DataFrames





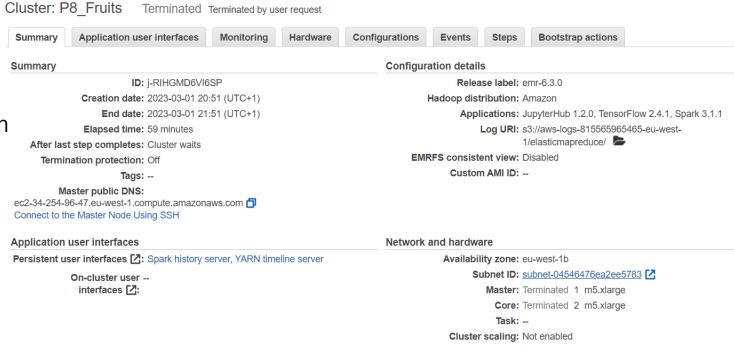
I) Création d'un environnement Big Data2) Calcul distribué : EMRApplication Spark

- Transformations et les Actions réalisées sur les RDD
- DAG (Directed Acyclic Graph): Graphe Acyclique Orienté

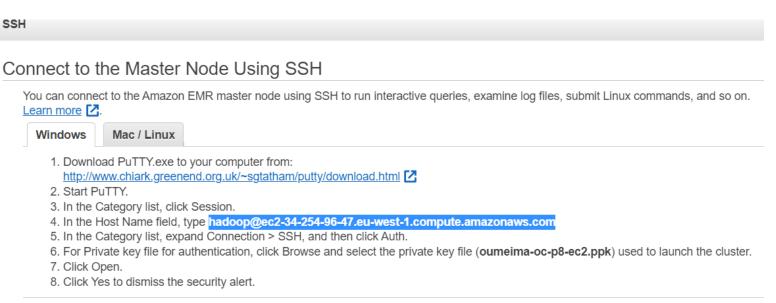


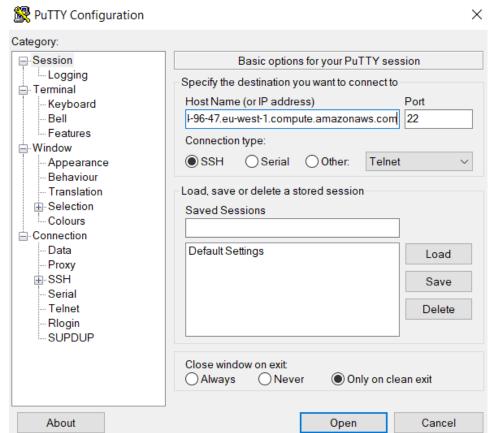
Création d'un cluster EMR

- Création dure 10 à 15 minutes
- Cluster : P8_Fruits
- Clé pour l'instance EC2
- Configuration json pour la persistance de S3 dans le cluster EMR
- Bootstraping: installation des packages python
- emr-6.3.0
- JupyterHub 1.2.0
- Tensorflow 2.4.1
- Spark 3.1.0

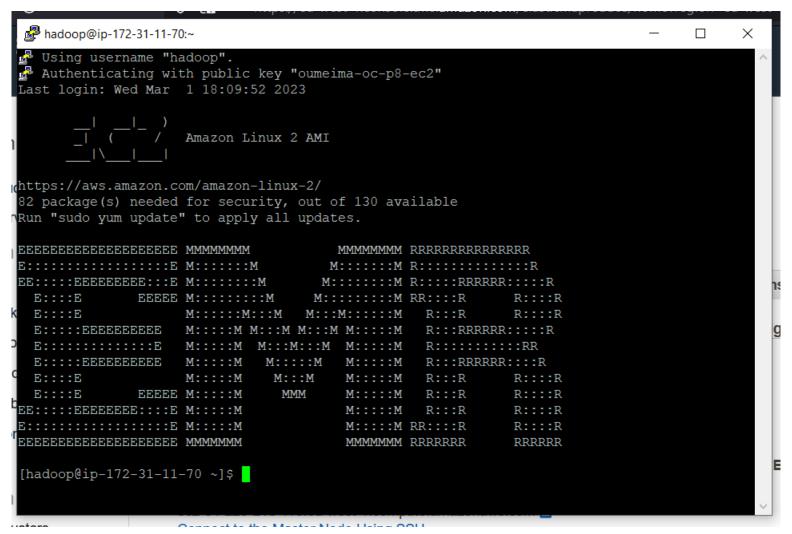


- Ajout de SSH en iPv4 et iPv6 dans la groupe de Sécurité
- Clé SSH et Tunnel SSH

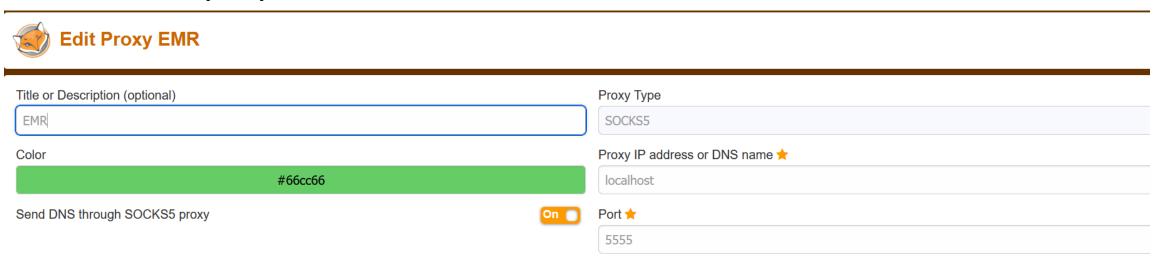




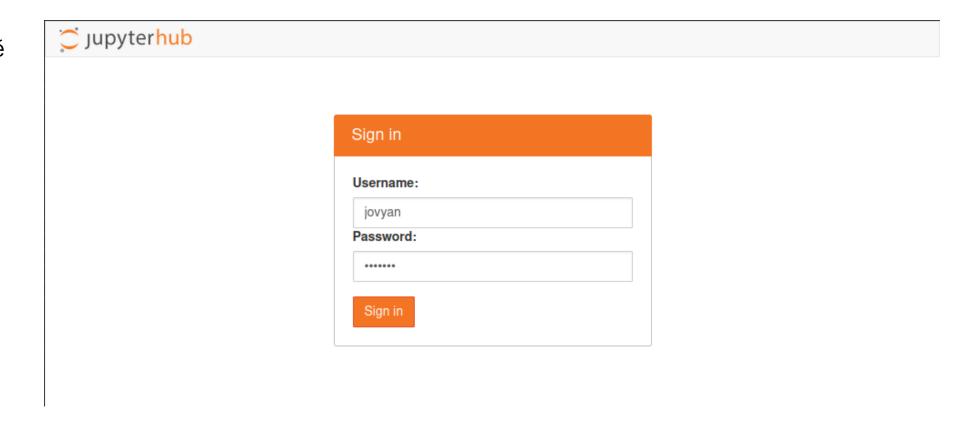
Connection SSH réussie



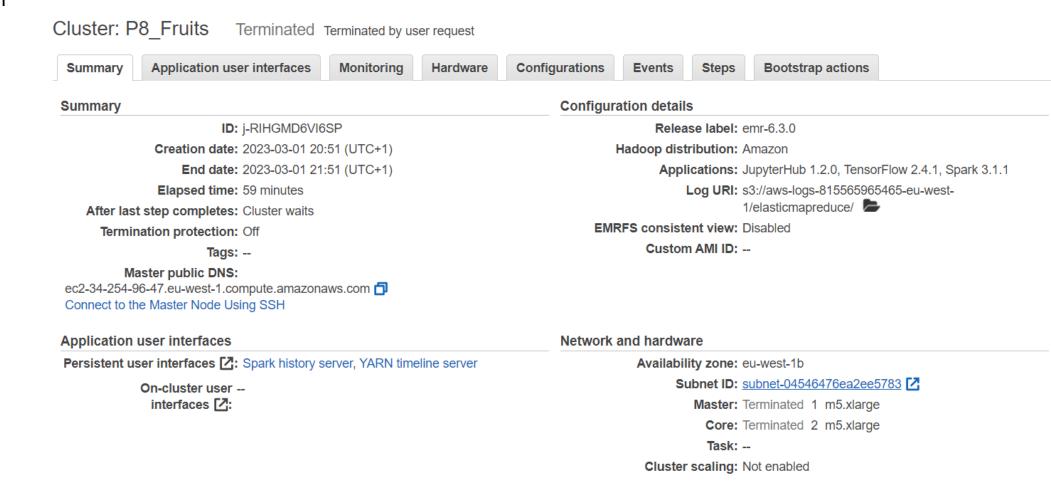
- Proxy
- Navigateur : Firefox
- Extension : FoxyProxy



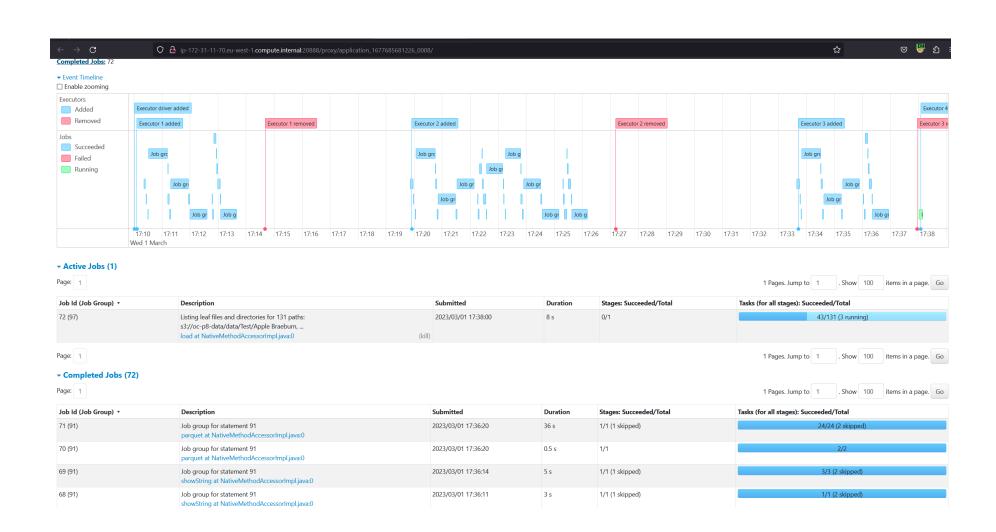
- Accès à Jupyter Hub!
- Kernel PySpark utilisé



- Résilier le cluster
- Cloner si besoin



Suivi des jobs Spark



Transfert Learning

ACP

Accès aux images dans le bucket grâce à la persistance (config json)

Création automatique du dossier « Results »

1.4 Définition des PATH pour charger les images et enregistrer les résultats

Nous accédons directement à nos données sur S3 comme si elles étaient stockées localement.

PATH: s3://oc-p8-data/data
PATH: s3://oc-p8-data/data
PATH_Data: s3://oc-p8-data/data/Test
PATH_Result: s3://oc-p8-data/data/Results

1.5.1 Chargement des données

```
images = spark.read.format("binaryFile").option("pathGlobFilter", "*.jpg").option("recursiveFileLookup", "true").load(PATH Data)
images.show(5)
                                                                  Je ne conserve que le **path** de l'image et j'ajoute
               path | modificationTime|length|
                                                       content
                                                                  une colonne contenant les **labels** de chaque image :
+----+
|s3://oc-p8-data/d...|2023-02-28 16:01:17| 7353|[FF D8 FF E0 00 1...|
|s3://oc-p8-data/d...|2023-02-28 16:01:18| 7350|[FF D8 FF E0 00 1...|
                                                                  images = images.withColumn('label', element at(split(images['path'], '/'), -2))
|s3://oc-p8-data/d...|2023-02-28 16:01:17| 7349|[FF D8 FF E0 00 1...|
                                                                  print(images.printSchema())
|s3://oc-p8-data/d...|2023-02-28 16:01:18| 7348|[FF D8 FF E0 00 1...|
                                                                  print(images.select('path', 'label').show(5, False))
|s3://oc-p8-data/d...|2023-02-28 16:01:18| 7328|[FF D8 FF E0 00 1...|
+-----
                                                                  root
only showing top 5 rows
```

Lecture des images en Spark

Reconnaissance d'images Architecture du Réseau de Neurones Convolutif MobileNetV2

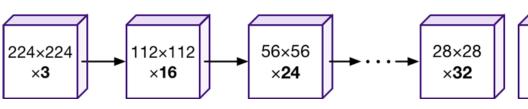
Input	Operator	t	c	n	s
$224^2 \times 3$	conv2d	-	32	1	2
$112^2 \times 32$	bottleneck	1	16	1	1
$112^{2} \times 16$	bottleneck	6	24	2	2
$56^2 \times 24$	bottleneck	6	32	3	2
$28^2 \times 32$	bottleneck	6	64	4	2
$14^2 \times 64$	bottleneck	6	96	3	1
$14^2 \times 96$	bottleneck	6	160	3	2
$7^2 \times 160$	bottleneck	6	320	1	1
$7^2 \times 320$	conv2d 1x1	-	1280	1	1
$7^2 imes 1280$	avgpool 7x7	-	-	1	-
$1\times1\times1280$	conv2d 1x1	-	k	-	

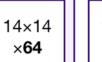
1.5.2 Préparation du modèle

outputs=model.layers[-2].output)

```
brodcast weights = sc.broadcast(new model.get weights())
```

```
new_model.summary()
```





14×14 ×**96**

7×7 **×160** 7×7 ×**320** 1×1 ×**1280**

1.5.3 Définition du processus de chargement des images et application de leur featurisation à travers l'utilisation de pandas UDF

```
def preprocess(content):
    Preprocesses raw image bytes for prediction.
    img = Image.open(io.BytesIO(content)).resize([224, 224])
    arr = img to array(img)
    return preprocess input(arr)
def featurize series(model, content series):
    Featurize a pd. Series of raw images using the input model.
    :return: a pd.Series of image features
    input = np.stack(content series.map(preprocess))
    preds = model.predict(input)
   # For some layers, output features will be multi-dimensional tensors.
    # We flatten the feature tensors to vectors for easier storage in Spark DataFrames.
    output = [p.flatten() for p in preds]
    return pd.Series(output)
@pandas udf('array<float>', PandasUDFType.SCALAR ITER)
def featurize udf(content series iter):
    This method is a Scalar Iterator pandas UDF wrapping our featurization function.
   The decorator specifies that this returns a Spark DataFrame column of type ArrayType(FloatType).
    :param content series iter: This argument is an iterator over batches of data, where each batch
                              is a pandas Series of image data.
    # With Scalar Iterator pandas UDFs, we can load the model once and then re-use it
    # for multiple data batches. This amortizes the overhead of loading big models.
    model = model fn()
    for content series in content series iter:
        yield featurize series(model, content series)
```

Préparation du preprocessing des images pour les adapter au format d'entrée de MobileNetV2

1.5.4 Exécutions des actions d'extractions de features

Preprocessing des images et générations des vecteurs de features d'image à l'aide du Transfert Learning

1.6 PCA

```
def scale_features(df_features):
   Returns the DataFrame entered as a parameter scaled using a Standard Scaler
   :param df features: (pyspark.sql.dataframe.DataFrame)
    :return:
    :rtype: pyspark.sql.dataframe.DataFrame
    # transform array to vector
   df features = df features.withColumn('features', array to vector('features'))
   print("Scaling features")
    # scale data
    scaler = StandardScaler(
       inputCol = 'features',
       outputCol = 'scaled features',
        withMean = True,
        withStd = True
   ).fit(df features)
   df features scaled = scaler.transform(df features)
   return df features scaled
```

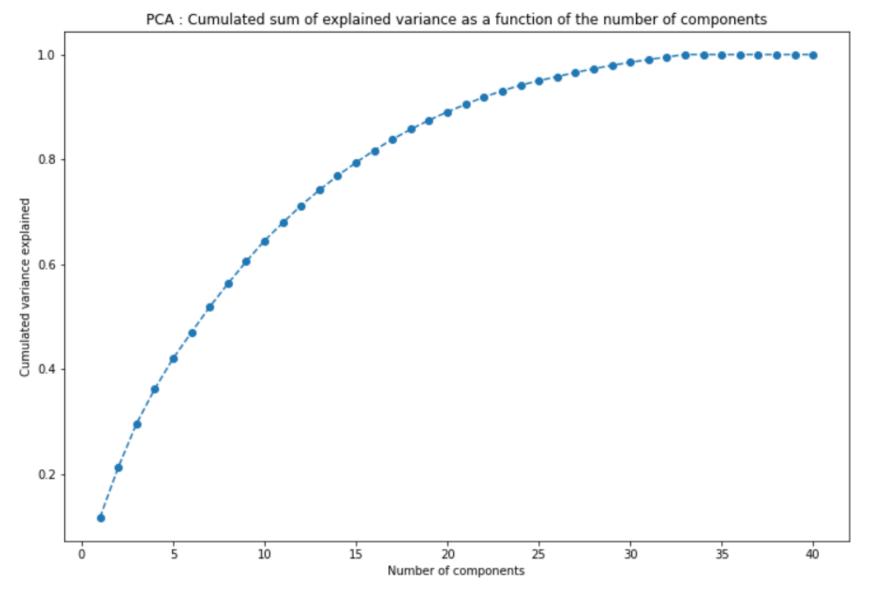
Réduction de dimension : Analyse en Composantes Principales

```
def get pca(df features scaled, n components=40):
    make pca on data scaled
    :param df features scaled: (pyspark.sql.dataframe.DataFrame)
    :param n components: (int) number of components to fit the PCA with
    print("Fitting PCA")
        k = n components, # output from Keras model is an array of dim ??
        inputCol = 'scaled features',
        outputCol = 'pca features'
    ).fit(df features scaled)
    return pca
def get_pca_features(pca_model, df_features_scaled):
    :param pca model:
    :param df features scaled: (pyspark.sql.dataframe.DataFrame)
    :rtype: pyspark.sql.dataframe.DataFrame
    Getting features based on PCA
    df features pca = pca model.transform(df features scaled)
    # drop scaled data
    # transform vector to array for saving
    df features pca = (df features pca
                        .drop("scaled features")
                       .withColumn('features', vector to array('features'))
                       .withColumn('pca features', vector to array('pca features')))
    return df features pca
```

Standardisation : moyenne = 0, écart-type = 1 Application de la PCA en PySpark

```
print("creating PCA")
features df pca = main pca(features df)
creating PCA
1-Scaling features
Scaling features
2-Creating pca model fitted on scaled features
Fitting PCA
3-Getting pca features
Enregistrement des données traitées au format "parquet" :
features df.show(2)
features df pca.show(2)
features df pca.write.mode("overwrite").parquet(PATH Result)
s3://oc-p8-data/d...| Watermelon|[0.8537659, 0.450...|
|s3://oc-p8-data/d...|Pineapple Mini|[0.0, 4.498071, 0...|
only showing top 2 rows
                                           features
|s3://oc-p8-data/d...| Watermelon|[0.84154003858566...|[-13.578741245307...|
|s3://oc-p8-data/d...|Pineapple Mini|[0.0, 4.333771705...|[-5.8529876532093...|
+-----
only showing top 2 rows
print("Computing time : {} seconds".format(time() - t0))
Computing time : 2216.4246039390564 seconds
```

Avec 35 à 40 composantes, on explique 99% de la variance des données.



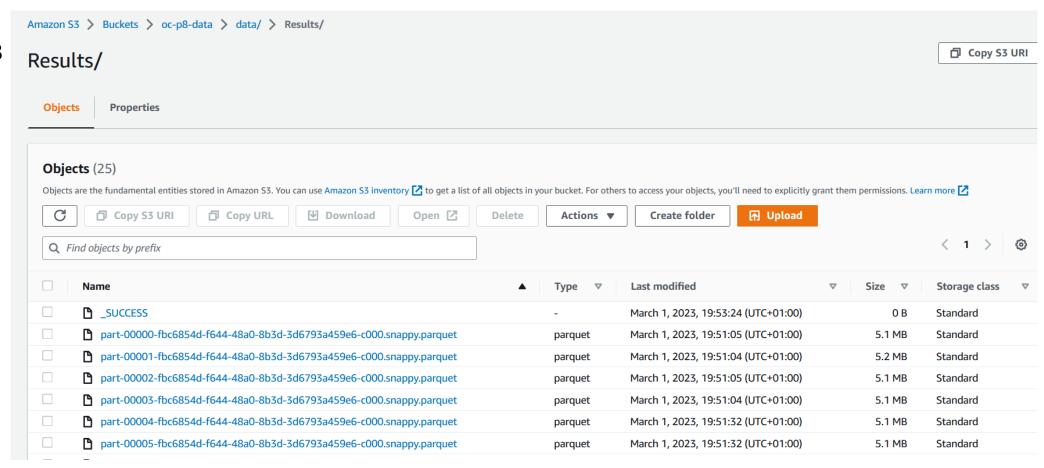
1	ററു	ı

	path	label	features	pca_features
0	file:/drive/My Drive/AI/OC/P8/data/Test1/Apple	Apple Crimson Snow	[0.0, 0.0, 0.0, 0.0, 0.0, 1.8282229900360107,	[7.623144376299502, 4.926324016170813, 4.20514
1	file:/drive/My Drive/AI/OC/P8/data/Test1/Water	Watermelon	[0.01282556727528572, 0.4700985848903656, 0.0,	[-11.049038780238458, -11.189032216304824, 6.0
2	file:/drive/My Drive/AI/OC/P8/data/Test1/Apple	Apple Red Yellow 1	[0.37628528475761414, 0.035564910620450974, 0	[10.306888619480848, -2.384498569050896, -7.86
3	file:/drive/My Drive/AI/OC/P8/data/Test1/Tomat	Tomato Yellow	[0.0, 0.7056543827056885, 0.0, 0.0, 0.0, 2.384	[10.203155492101946, 6.450768106599577, -5.278
4	file:/drive/My Drive/AI/OC/P8/data/Test1/Apple	Apple Golden 1	[0.0, 0.003275326220318675, 1.0620614290237427	[0.19016565809646457, -6.611334741220691, 11.9

Mon Drive > · · · > data > Results_local -

Nom	↑	Propriétaire	Dernière modific	Taille du fichier
	_SUCCESS	moi	27 févr. 2023	0 octet
	SUCCESS.crc	moi	27 févr. 2023	8 octets
	.part-00000-2f6729b9-7243-4083-883a-274f2f6afd3b-c000.sna	moi	27 févr. 2023	120 octets
	.part-00001-2f6729b9-7243-4083-883a-274f2f6afd3b-c000.sna	moi	27 févr. 2023	72 octets
	.part-00002-2f6729b9-7243-4083-883a-274f2f6afd3b-c000.sna	moi	27 févr. 2023	72 octets
	.part-00003-2f6729b9-7243-4083-883a-274f2f6afd3b-c000.sna	moi	27 févr. 2023	76 octets

EMR et S3



III) Démo

Cluster EMR prêt

Lancement du notebook (P8_Notebook_AWS.ipynb) sur Jupyter Hub

Conclusion

- Architecture Big Data
- Architecture basé sur Spark (Hadoop MapReduce)
- Stockage des données sur S3
- Calcul distribué sur un cluster EMR (serveur EC2)
- Featurisation et ACP durent 5 minutes sur 34 images
- Featurisation et ACP dure 36 minutes sur 22668 images
- Sauvegarde au format parquet
- Axes d'améliorations:
- Optimisation des performances PySpark : réduire le temps de calcul des jobs de 5 min
- Coûts de l'infrastructure AWS



Merci!